

STATISTICAL HEALTH REPORT

kubernetes/kubernetes

-Stat Prob-

Dosen Pengampu:

Muhammad Ridho Kurniawan Pratama, S.Kom., M.T.I.



Intelligentia - Dignitas

Disusun oleh:

- | | |
|----------------------------|--------------|
| 1. Muhammad Asrofi Syaikho | (1519625049) |
| 2. Amila Zahira | (1519625003) |
| 3. Mukgot Ega Saputra | (1519625002) |
| 4. Nabila Nurfajriyasah | (1519625045) |
| 5. Farhan Nabil Widodo | (1519625067) |

**SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS NEGERI JAKARTA
2026**

1. Ringkasan Eksekutif

Laporan ini menyajikan hasil audit statistik menyeluruh terhadap repositori kubernetes/kubernetes, platform orkestrasi container skala enterprise yang digunakan secara global. Data dikumpulkan melalui GitHub API mencakup 1.213 issues dan 5.000 Pull Request (PR), kemudian dianalisis menggunakan teknik estimasi, inferensi, uji hipotesis, dan simulasi komputasional

Temuan Utama untuk Maintainer:

- Tingkat keberhasilan merge PR sebesar 57,2% — lebih dari separuh PR yang diajukan berhasil diterima, menunjukkan kualitas kontribusi yang layak namun masih ada ruang peningkatan proses review.
- Rata-rata penyelesaian issue (34,40 hari) melebihi batas wajar 30 hari secara signifikan ($z = 2,32$, $p = 0,0102$), mengindikasikan perlunya percepatan respons tim terhadap laporan masalah.
- Waktu merge PR (16,29 hari) berbeda signifikan dari target 14 hari ($z = 4,28$, $p \approx 0,000$), menunjukkan bottleneck dalam proses review kode yang perlu diatasi.
- Simulasi Monte Carlo (20.000 iterasi) menunjukkan probabilitas 83,60% bahwa rata-rata PR akan membutuhkan lebih dari 14 hari untuk di-merge, mengkonfirmasi tantangan efisiensi yang nyata.
- Bloom Filter dengan 6 fungsi hash ($k=6$) mampu menurunkan False Positive Rate menjadi $\sim 2,6 \times 10^{-6}$, menawarkan solusi caching yang sangat efisien untuk pemeriksaan duplikasi issue.

2. Tinjauan Data

2.1 Sumber Data

Atribut	Detail
Repositori	kubernetes/kubernetes
URL Sumber	https://api.github.com/repos/kubernetes/kubernetes
Metode Pengumpulan	GitHub REST API v3 (pagination, 100 items/page)
Token Autentikasi	Personal Access Token via variabel lingkungan .env
Tanggal Pengambilan Data	Mei 2026
Rentang Waktu Data Issues	September 2025 – Mei 2026
Rentang Waktu Data PRs	September 2025 – Mei 2026
Script Pengumpulan	collecting_data.py (Member A)

2.2 Deskripsi Variable

Dimensi	Issues	Pull Requests
Total Data Mentah	1.213 baris	5.000 baris
Jumlah Kolom	7 kolom	9 kolom
Data dengan Waktu Resolusi	708 (closed)	2.860 (merged)
Fitur Kunci	id, state, is_bug, time_to_close_days	id, is_merged, duration_to_merge_days

2.3 Keterbatasan Data

- Data API bersifat paginated dengan batas 100 item/halaman dan rate limit GitHub, sehingga sampel PR dibatasi 5.000 entri terbaru dan tidak mencakup seluruh riwayat repositori sejak 2014.
- Kolom labels pada dataset issues disimpan sebagai string representasi list Python, sehingga deteksi label "kind/bug" dilakukan via `str.contains()` yang mungkin melewatkan variasi penulisan label lain yang serupa.
- Sebagian issues berstatus "open" tidak memiliki nilai `closed_at`, sehingga metrik `time_to_close_days` hanya dapat dihitung untuk 708 dari 1.213 issues (58,4% populasi).

3. Estimasi Parameter

Bagian ini menerapkan Maximum Likelihood Estimation (MLE) untuk dua distribusi: Bernoulli (variabel biner) dan Poisson (variabel cacah). Seluruh formula mengikuti Tsun (2020).

3.1 MLE Bernoulli

Research Question 1: Berapa estimasi probabilitas sebuah PR akan berhasil di-merge?

Penurunan MLE

Misalkan setiap PR merupakan percobaan Bernoulli independen dengan parameter θ . Log-likelihood-nya adalah:

$$\ell(\theta) = k \cdot \log(\theta) + (n - k) \cdot \log(1 - \theta)$$
$$d\ell/d\theta = 0 \Rightarrow \hat{\theta} = k / n$$

Hasil Estimasi

Parameter	Nilai	Keterangan
n (total PR)	5.000	Ukuran sampel
k (PR merged)	2.860	Jumlah sukses
$\theta = k/n$	0,5720	MLE Bernoulli (Tsun, 2020, p. 254)
Log-likelihood di θ	-3.413,72	Nilai maksimum log-likelihood

3.2 Beta Posterior

Menggunakan prior Beta(1,1) (non-informatif), posterior dihitung dengan formula:

$$\alpha = k + 1 = 2.861$$
$$\text{Mean} = \alpha / (\alpha + \beta) = 0,5720$$

$$\beta = (n - k) + 1 = 2.141$$
$$\text{Mode} = (\alpha - 1) / (\alpha + \beta - 2) = 0,5720$$

3.3 MLE Poisson

Research Question (tambahan): Berapa rata-rata jumlah issue baru yang dibuka per bulan di repositori Kubernetes?

Hasil Estimasi

Bulan	Jumlah Issue
Sep 2025	40
Okt 2025	163
Nov 2025	139
Des 2025	116
Jan 2026	144
Feb 2026	156
Mar 2026	215
Apr 2026	133
Mei 2026	107

$$\hat{\lambda} = (1/n) \cdot \sum x_i = 1.213 / 9 = 134,78 \text{ issue/bulan}$$

Log-likelihood di $\hat{\lambda}$: -105,56 | Referensi: Tsun (2020), p. 254

Nilai $\hat{\lambda} \approx 134,78$ berarti repositori Kubernetes menerima rata-rata sekitar 135 issue baru per bulan. Puncak tertinggi terjadi pada Maret 2026 (215 issue), sementara

terendah pada September 2025 (40 issue) yang kemungkinan merupakan bulan pertama pengambilan data sehingga data belum penuh.

4. Confidence Interval

4.1 CI untuk Waktu Resolusi Issue (Bug vs Non-Bug)

4.2 CI untuk λ Poisson (Frekuensi Issue Bulanan)

4.3 Credible Interval Bayesian untuk Merge Rate PR

5. Pengujian Hypotesis

Pada hypotesis testing dilakukan tiga pengujian menggunakan Z-Test, dengan 6 prosedur langkah. Pengujian ini tidak ada istilah “accept H_0 .”, kesimpulan dari pengujian hanya berupa “Reject H_0 ” atau “Fail to Reject H_0 .”

5.1 Uji 1

1. Identifikasi

Identifikasi dilakukan klaim dengan melihat apakah ada perbedaan performa kecepatan penanganan antara keluhan berkategori Bug dengan keluhan Non-Bug.

2. Merumuskan hipotesis

Hipotesis ini diterjemahkan ke dalam hipotesis statistik uji dua arah.

- H_0 : Rata-rata waktu close Bug = Rata-rata waktu close Non-Bug
- H_1 : Rata-rata waktu close Bug $\neq$ Rata-rata waktu close Non-Bug

Pada Hipotesis Nol menyatakan rata-rata waktu penyelesaian kedua kelompok adalah sama (tidak ada perbedaan signifikan). Sementara Hipotesis Alternatif menyatakan bahwa rata-rata waktunya berbeda.

3. Batas Signifikansi

Tingkat signifikansi yang ditetapkan dalam pengujian ini adalah $\alpha = 0,05$

4. Kumpulkan data

Setelah membersihkan data dari nilai yang kosong, didapatkan sampel observasi berupa 257 data Bug dengan rata-rata penyelesaian 34,65 hari, serta 451 data Non-Bug dengan rata-rata penyelesaian 34,26 hari.

- Kelompok Bug : Mean=34.65, Std=49.17, n=257
- Kelompok Non-Bug: Mean=34.26, Std=51.33, n=451

5. Hitung

Hasil dari perhitungan matematis menghasilkan nilai statistik $z = 0,0981$ dan $p\text{-value} = 0.9219$.

6. Keputusan dan interpretasi

Dengan membandingkan nilai P-Value dengan alpha, dapat dikatakan bahwa P-Value sebesar 0.9219 jauh lebih besar dari $\alpha = 0.05$, maka keputusannya adalah Gagal Menolak H_0 (Fail To Reject H_0).

Dapat disimpulkan bahwa pengujian tersebut gagal menolak Hipotesis Nol yang telah diajukan dan dalam menjawab *research question* (“apakah terdapat perbedaan waktu penyelesaian (*time-to-close*) yang signifikan secara statistik antara issue yang berlabel *bug* dan *non-bug*”), hasil pengujian menunjukkan bahwa tidak terdapat perbedaan yang signifikan secara statistik pada rata-rata waktu penanganan antara kedua jenis issue tersebut. Dengan demikian, baik keluhan *bug* maupun *non-bug* ditangani dengan tingkat kecepatan yang relatif setara.

6. Analisis Komputasional

6.1 Simulasi Simulasi Monte Carlo

Research Question 3: Berapa peluang sebuah Pull Request (PR) baru memerlukan waktu lebih dari 14 hari hingga berhasil di-merge?

Metrik	Nilai
Jumlah simulasi dijalankan	20.000 iterasi
Ambang batas hari pengujian	14,0 hari
Probabilitas rata-rata > 14 hari	0,836050 (83,60%)
Rata-rata dari distribusi simulasi	~16,29 hari

Hasil Simulasi

$$P(\text{rata-rata durasi PR} > 14 \text{ hari}) = 0,8360 \quad (83,60\%)$$

Berdasarkan 20.000 iterasi bootstrap resampling

Hasil simulasi menunjukkan bahwa **83,60%** dari seluruh iterasi menghasilkan rata-rata durasi merge PR di atas **14 hari**. Dengan ukuran sampel **150 PR**, peluang rata-rata waktu merge melebihi target dua minggu mencapai sekitar **84%**. Kondisi ini

mengindikasikan bahwa proses pengelolaan dan penyelesaian PR masih berlangsung lebih lambat dibandingkan target yang ditetapkan.

6.2 Bloom Filter

Tabel berikut menyajikan nilai FPR teoritis untuk setiap nilai k yang diuji, dengan parameter $m = 8.000$ dan $n = 1.000$:

Jumlah Hash (k)	FPR Nilai Mentah	Keterangan
1	1.175100e-01	0.1175 (11.75%)
2	1.380860e-02	0.0138 (1.38%)
3	1.622648e-03	0.0016 (0.16%)
4	1.906774e-04	~0.019%
5	2.240650e-05	~0.002%
6	2.632987e-06	~0.00026%
7	3.094023e-07	~ $2.9 \times 10^{-5}\%$
8	3.635787e-08	~ $3.6 \times 10^{-6}\%$
9	4.272413e-09	~ $4.3 \times 10^{-7}\%$
10	5.020512e-10	~ $5.0 \times 10^{-8}\%$
11	5.899603e-11	~ $5.9 \times 10^{-9}\%$
12	6.932623e-12	~ $6.9 \times 10^{-10}\%$
13	8.146525e-13	~ $8.1 \times 10^{-11}\%$
14	9.572981e-14	~ $9.6 \times 10^{-12}\%$
15	1.124921e-14	~$1.1 \times 10^{-12}\%$ (OPTIMAL)

Melalui evaluasi matematis menggunakan rumus wajib $(1 - (1 - 1/m)^{n/k})^k$, kita berhasil memetakan titik minimum kurva trade-off. Penambahan fungsi hash k pada awalnya mampu menekan nilai False Positive, namun jika melewati titik optimumnya, penambahan hash justru akan memperbanyak kepadatan bit bernilai 1 di memori, sehingga menaikkan kembali risiko terjadinya kesalahan deteksi data (False Positive).

7. Rekomendasi

Sebagai rekomendasi, proses scraping data dapat diperluas agar lebih banyak data yang tersedia dapat dimanfaatkan dalam analisis. Mengingat jumlah data pada repository cukup besar, penggunaan dataset yang lebih lengkap diharapkan dapat meningkatkan representativitas data serta menghasilkan analisis yang lebih akurat.